

Домашнее задание 3

Лиза Фоменко

Задание 1

Пусть $X = (X_1, \dots, X_n)$ - выборка,

$$p_{X_1}(x, \theta) = e^{-x+\theta} I(x > \theta), \quad \theta \in \mathbb{R}.$$

- (a) Используя $\sum_{i=1}^n X_i - n\theta \sim \Gamma(1, n)$, постройте точный доверительный интервал уровня $1 - \alpha$ для параметра θ .
- (b) Постройте асимптотический доверительный интервал уровня $1 - \alpha$ для параметра θ .

Пункт а

Можно сразу написать функцию распределения $\Gamma(1, n) : F_G(t) = 1 - e^{-nt}$

$G(X, \theta) = \sum_{i=1}^n X_i - n\theta \sim \Gamma(1, n)$, соответственно распределение ее не зависит от θ и это центральная статистика.

Доверительный интервал: $P_\theta(g_1 < G(X, \theta) < g_2) = F_G(g_2) - F_G(g_1) = 1 - \alpha$

Распишем как в лекции на странице 27 (так как $G(X, \theta)$ непрерывна и монотонна по θ): $P_\theta(g_1 < G(X, \theta) < g_2) = P_\theta(T_1(X) < \theta < T_2(X))$. Перейдем к выбору g_1 и g_2 из условия: $F_G(g_1) = \frac{\alpha}{2}$, $F_G(g_2) = 1 - \frac{\alpha}{2} \Rightarrow g_1 = F_G^{-1}(\frac{\alpha}{2})$ $g_2 = F_G^{-1}(1 - \frac{\alpha}{2})$

Теперь нам нужно найти обратную функцию $F_G^{-1}(t)$, где $F_G(t) = 1 - e^{-nt}$. $F_G^{-1}(t) = -\frac{1}{n} \ln(1 - t)$

Посчитав:

$$g_1 = -\frac{1}{n} \ln(1 - \frac{\alpha}{2}) \quad g_2 = -\frac{1}{n} \ln(\frac{\alpha}{2})$$

Тогда: $P_\theta(-\frac{1}{n} \ln(1 - \frac{\alpha}{2}) < \sum_{i=1}^n X_i - n\theta < -\frac{1}{n} \ln(\frac{\alpha}{2})) = 1 - \alpha$

Вытаскиваем сам интервал $-\frac{1}{n} \ln(1 - \frac{\alpha}{2}) < \sum_{i=1}^n X_i - n\theta < -\frac{1}{n} \ln(\frac{\alpha}{2})$

Решим относительно θ и получим следующее неравенство: $\bar{X} + \frac{1}{n^2} \ln(\frac{\alpha}{2}) < \theta < \bar{X} + \frac{1}{n^2} \ln(1 - \frac{\alpha}{2})$

Получили точный доверительный интервал $(\bar{X} + \frac{1}{n^2} \ln(\frac{\alpha}{2}), \bar{X} + \frac{1}{n^2} \ln(1 - \frac{\alpha}{2}))$

Пункт б

Мы используем $\sqrt{n}$ -Гауссовские оценки. Тогда формула асимптотической оценки:

$$P_\theta \left(Z_{\frac{\alpha}{2}} < \frac{\sqrt{n}(\hat{\theta}_n(X) - \theta)}{\sigma(\theta)} < Z_{1-\frac{\alpha}{2}} \right) \rightarrow 1 - \alpha$$

Распишем ($\sigma(\theta)$ заменено на $\sigma(\hat{\theta}_n)$)

$$I_n(X) = \left(\hat{\theta}_n(X) - \frac{\sigma(\hat{\theta}_n)}{\sqrt{n}} Z_{1-\frac{\alpha}{2}}; \hat{\theta}_n(X) + \frac{\sigma(\hat{\theta}_n)}{\sqrt{n}} Z_{1-\frac{\alpha}{2}} \right)$$

Найдем $\hat{\theta}_n(X)$ и $\sigma(\hat{\theta}_n)$

$$E(X) = \int_{-\infty}^{\infty} x e^{-x+\theta} I(x > \theta) dx = \int_{\theta}^{\infty} x e^{-x+\theta} dx = e^{\theta} \int_{\theta}^{\infty} x e^{-x} dx = e^{\theta} (\theta + 1) e^{-\theta} = \theta + 1, \text{ тогда } \hat{\theta}_n = \bar{X} - 1$$

$$Var(\hat{\theta}_n) = Var(\bar{X} - 1) = \frac{Var(X)}{n}, \text{ ищем } Var(X)$$

$$E(X^2) = 2 + 2\theta + \theta^2$$

$$Var(X) = E(X^2) - E(X)^2 = 2 + 2\theta + \theta^2 - (\theta + 1)^2 = 1$$

$$\text{Тогда } Var(\hat{\theta}_n) = \frac{1}{n}, \text{ откуда } \sigma(\hat{\theta}_n) = \frac{1}{\sqrt{n}}$$

Overall, подставляем в формулу

$$I_n(X) = \left(\bar{X} - 1 - \frac{Z_{1-\frac{\alpha}{2}}}{n}; \bar{X} - 1 + \frac{Z_{1-\frac{\alpha}{2}}}{n} \right)$$

Задание 2

Пусть $X = (X_1, \dots, X_n)$ - выборка, $X_1 \sim U[0, \theta]$, $\theta > 0$.

- (а) (1 балл) Используя одну из статистик $X_{(1)}, X_{(n)}, \bar{X}$, постройте точный доверительный интервал уровня $1 - \alpha$ для параметра θ .
- (б) (1 балл) Постройте асимптотический доверительный интервал уровня $1 - \alpha$ для параметра θ .
- (с) (2 балла) Постройте РНМК уровня значимости α для проверки гипотезы $H_0 : \theta = \theta_0$ против $H_1 : \theta < \theta_0$ в виде $S(X_1, \dots, X_n) = X_{(n)} \leq c\theta_0$ (определить явный вид c и доказать, что данный критерий является РНМ.)

Пункт а

здесь прям просится статистика $X_{(n)}$, функция распределения у нее

Пусть $X = (X_1, \dots, X_n)$ — выборка из распределения $U[0, \theta]$, $\theta > 0$.

Рассмотрим статистику $X_{(n)} = \max(X_1, \dots, X_n)$. Её функция распределения $p_{X_{(n)}}(x) = (\frac{x}{\theta})^n$

Возьмем центральную статистику $G(X, \theta)$, которая непрерывна и монотонна по $\theta > 0$: $G(X, \theta) = \frac{X_{(n)}}{\theta}$

Доверительный интервал: $P_\theta(g_1 < G(X, \theta) < g_2) = F_G(g_2) - F_G(g_1) = 1 - \alpha$

Распишем как в лекции на странице 27 (так как $G(X, \theta)$ непрерывна и монотонна по θ): $P_\theta(g_1 < G(X, \theta) < g_2) = P_\theta(T_1(X) < \theta < T_2(X))$. Перейдем к выбору g_1 и g_2 из условия: $F_G(g_1) = \frac{\alpha}{2}$, $F_G(g_2) = 1 - \frac{\alpha}{2} \Rightarrow g_1 = F_G^{-1}(\frac{\alpha}{2})$ $g_2 = F_G^{-1}(1 - \frac{\alpha}{2})$

Пора найти F_G , где $G(X, \theta) = \frac{X_{(n)}}{\theta}$. Зная распределение $X_{(n)}$, мы можем понять, что $F_G(t) = t^n$. То есть $F_G^{-1}(t) = t^{1/n}$.

Отсюда $g_1 = (\frac{\alpha}{2})^{1/n}$ $g_2 = (1 - \frac{\alpha}{2})^{1/n}$

Подставим обратно $P_\theta((\frac{\alpha}{2})^{1/n} < \frac{X_{(n)}}{\theta} < (1 - \frac{\alpha}{2})^{1/n}) = 1 - \alpha$

Вытаскиваем сам интервал $(\frac{\alpha}{2})^{1/n} < \frac{X_{(n)}}{\theta} < (1 - \frac{\alpha}{2})^{1/n}$

Решим относительно θ и получим следующее неравенство: $\frac{X_{(n)}}{(1 - \frac{\alpha}{2})^{1/n}} < \theta < \frac{X_{(n)}}{(\frac{\alpha}{2})^{1/n}}$

Получили точный доверительный интервал $\left(\frac{X_{(n)}}{(1 - \frac{\alpha}{2})^{1/n}}, \frac{X_{(n)}}{(\frac{\alpha}{2})^{1/n}} \right)$

Пункт б

Мы используем $\sqrt{n}$ -Гауссовские оценки. Тогда формула асимптотической оценки:

$$P_\theta \left(Z_{\frac{\alpha}{2}} < \frac{\sqrt{n}(\hat{\theta}_n(X) - \theta)}{\sigma(\theta)} < Z_{1 - \frac{\alpha}{2}} \right) \rightarrow 1 - \alpha$$

Распишем ($\sigma(\theta)$ заменено на $\sigma(\hat{\theta}_n)$)

$$I_n(X) = \left(\hat{\theta}_n(X) - \frac{\sigma(\hat{\theta}_n)}{\sqrt{n}} Z_{1 - \frac{\alpha}{2}}; \hat{\theta}_n(X) + \frac{\sigma(\hat{\theta}_n)}{\sqrt{n}} Z_{1 - \frac{\alpha}{2}} \right)$$

Найдем $\hat{\theta}_n(X)$ и $\sigma(\hat{\theta}_n)$

$E(X) = \frac{\theta}{2}$, тогда $\hat{\theta}_n = 2\bar{X}$

$Var(\hat{\theta}_n) = Var(2\bar{X}) = 4Var\bar{X} = 4\frac{Var(X)}{n}$, ищем $Var(X)$

$E(X^2) = \frac{\theta^2}{3}$ (база для $U[a, b]$)

$Var(X) = E(X^2) - E(X)^2 = \frac{\theta^2}{3} - \frac{\theta^2}{4} = \frac{\theta^2}{12}$

Тогда $Var(\hat{\theta}_n) = 4\frac{\theta^2}{12n} = \frac{\theta^2}{3n}$, откуда $\sigma(\hat{\theta}_n) = \frac{\theta}{\sqrt{3n}}$

Overall, подставляем в формулу

$$I_n(X) = \left(2\bar{X} - \frac{\theta}{\sqrt{3n}} Z_{1 - \frac{\alpha}{2}}; 2\bar{X} + \frac{\theta}{\sqrt{3n}} Z_{1 - \frac{\alpha}{2}} \right)$$

У нас тут фигурирует θ , что, наверное, не очень хорошо. Давайте ее тоже заменим на $\hat{\theta}_n = 2\bar{X}$

$$I_n(X) = \left(2\bar{X} - \frac{2\bar{X}}{\sqrt{3n}} Z_{1 - \frac{\alpha}{2}}; 2\bar{X} + \frac{2\bar{X}}{\sqrt{3n}} Z_{1 - \frac{\alpha}{2}} \right) = 2\bar{X} \left(1 - \frac{Z_{1 - \frac{\alpha}{2}}}{\sqrt{3n}}; 1 + \frac{Z_{1 - \frac{\alpha}{2}}}{\sqrt{3n}} \right)$$

Пункт с

$$p_\theta(x) = \frac{1}{\theta^n} I(X_{(n)} \leq \theta)$$

$$\frac{p_1(x)}{p_0(x)} = \frac{\frac{I(X_{(n)} \leq \theta_1)}{\theta_1^n}}{\frac{I(X_{(n)} \leq \theta_0)}{\theta_0^n}} = \frac{I(X_{(n)} \leq \theta_1)}{I(X_{(n)} \leq \theta_0)} \frac{\theta_0^n}{\theta_1^n}$$

Если $x_{(n)} > \theta_1$, то $I(X_{(n)} \leq \theta_1) = 0$ и, следовательно, $p_{\theta_1}(x) = 0$. А вот если $x_{(n)} \leq \theta_1$, то

$$\frac{p_1(x)}{p_0(x)} = \frac{\theta_0^n}{\theta_1^n}$$

Мы знаем, что $\theta_1 < \theta_0$ и это константы, поэтому $\frac{\theta_0^n}{\theta_1^n}$ - константа > 1 .

Тогда $S(\lambda) = \{x : X_{(n)} \leq c\theta_0\}$

Найдём c из условия, что вероятность ошибки I рода равна α

плотность для максимума мы уже находили, она равна $(\frac{x}{\theta})^n$

$\alpha = P_{\theta_0}(X_{(n)} \leq c\theta_0) = (\frac{c\theta_0}{\theta_0})^n = c^n$, откуда $c = \alpha^{\frac{1}{n}}$

Можем сформировать критическое множество $S_\alpha^* = \{X_{(n)} \leq \theta_0 \alpha^{\frac{1}{n}}\}$

Берём $\forall$ критерий S_α : $P_{\theta_0}(X \in S_\alpha) \leq \alpha = P_{\theta_0}(X \in S_\alpha^*) \Rightarrow$ выполнено условие леммы Неймана-Пирсона

$\Rightarrow P_{\theta_1}(X \in S_\alpha) \leq P_{\theta_1}(X \in S_\alpha^*) \Rightarrow S_\alpha^*$ - наиболее мощный критерий.

$S_\alpha^* = \{X_{(n)} \leq \theta_0 \alpha^{\frac{1}{n}}\}$ не зависит от $\theta_1 \Rightarrow$ критерий S_α^* является равномерно наиболее мощным критерием для гипотез $H_0 : \theta = \theta_0$ против сложной (левосторонней) альтернативы: $H_1^- : \theta < \theta_0$.

Задание 3

По статистике, собранной в психиатрической больнице в течение года, количество пациентов, поступивших в отделение интенсивной терапии, имело следующее распределение по дням недели:

ПН - 36, ВТ - 53, СР - 35, ЧТ - 26,
ПТ - 30, СБ - 44, ВС - 28.

Согласуются ли эти данные с гипотезой о том, что попадание в отделение не зависит от дня недели на уровне значимости 0.05?

- Предоставьте аналитическое решение задачи.
- Предоставьте программное решение задачи (можно пользоваться известными библиотеками).

Пункт а

Классический пример для хи-квадрата. Предполагаем равномерное распределение, поэтому Expected

$$= \frac{\text{total observations}}{\text{num classes}} = \frac{252}{7} = 36$$

-	ПН	ВТ	СР	ЧТ	ПТ	СБ	ВС
Expected	36	36	36	36	36	36	36
Observed	36	53	35	26	30	44	28

Вычисляем статистику: $\chi_n^2 = \sum_{i=1}^7 \frac{(\text{Obs}_i - \text{Exp}_i)^2}{\text{Exp}_i} = 15.389$

$df = 6, \alpha = 0.05$. Смотрим критическое значение в таблице: $\chi_{0.05}^2(6) = 12.592$

$15.389 > 12.592 \Rightarrow H_0$ отвергается: все-таки попадание в больницу зависит от дня недели

Пункт б

Не вижу смысла еще один файл делать ради трех строк кода. держите скрин

```
import scipy.stats as sts

result = sts.chisquare(f_obs = [36, 53, 35, 26, 30, 44, 28])

print(f'Chi2 test with {6} degrees of freedom: \n\t statistic = {result.statistic:.3f} \n\t p-value = {result.pvalue:.4f}')
```

Chi2 test with 6 degrees of freedom:
statistic = 15.389
p-value = 0.0174

Задание 4

Проверьте на уровне значимости 0.05 гипотезу о том, что измеряемая величина X имеет биномиальное распределение с параметрами $(2, \theta)$, если при проведении $n = 128$ экспериментов она $\mu_1 = \frac{n}{4}$ раз приняла значение 0, $\mu_2 = \frac{n}{4}$ раз значение 1 и $\mu_3 = \frac{n}{2}$ раз значение 2. (Подсказка: воспользоваться критерием хи-квадрат Пирсона, в котором участвует ОМП)

По методу максимального правдоподобия найдем θ

Пишем likelihood function

$$L(\theta, X) = \prod_i P(x_i, \theta) = \theta^{2 \cdot \frac{n}{2}} * (2\theta(1-\theta))^{\frac{n}{4}} * (1-\theta)^{2 \cdot \frac{n}{4}} = \theta^n * (2\theta(1-\theta))^{\frac{n}{4}} * (1-\theta)^{\frac{n}{2}}$$

логарифмируем

$$\ln L(\theta, X) = \ln(\theta^n * (2\theta(1-\theta))^{\frac{n}{4}} * (1-\theta)^{\frac{n}{2}}) = n \ln \theta + \frac{n}{4} (\ln 2 + \ln \theta + \ln(1-\theta)) + \frac{n}{2} (\ln(1-\theta)) = \frac{5n}{4} \ln \theta + \frac{3n}{4} \ln(1-\theta) + \frac{n}{4} \ln 2$$

Дифференцируем по θ

$$\frac{d}{d\theta} \left(\frac{5n}{4} \ln \theta + \frac{3n}{4} \ln(1-\theta) + \frac{n}{4} \ln 2 \right) = \frac{5n}{4\theta} - \frac{3n}{4(1-\theta)}$$

Приравниваем к 0 и находим оценку

$$\frac{5n}{4\theta} - \frac{3n}{4(1-\theta)} = 0 \Rightarrow \hat{p} = 0.625$$

Теперь можем это юзать в тесте Хи квадрат.

-	0	1	2
Expected	$\frac{9}{64}n$	$\frac{15}{32}n$	$\frac{25}{64}n$
Observed	$\frac{n}{4}$	$\frac{n}{4}$	$\frac{n}{2}$

Вычисляем статистику: $\chi_n^2 = \sum_{i=1}^3 \frac{(\text{Obs}_i - \text{Exp}_i)^2}{\text{Exp}_i} = 0.211n \sim 27$

$df = 2, \alpha = 0.05$. Смотрим критическое значение в таблице: $\chi_{0.05}^2(2) = 5.99$
 $27 \gg 5.99$, поэтому H_0 отвергается.